

第24回 日本テスト学会 @実践女子大学  
2026年9月15日 (火)  
一般セッション3-2.

# 正答確率データと離散的反応データを 統合する大規模言語モデルのIRT分析手法

高山 正行<sup>1</sup>、清水 昌平<sup>2,3</sup>

1. 滋賀大学 データサイエンス・AIイノベーション研究推進センター
2. 大阪大学 産業科学研究所
3. 滋賀大学 データサイエンス学系

■ pythonコード等の格納先: <https://github.com/mas-takayama/IRT-Measurement-for-LLMs/tree/main/JART%2024th>  
(抄録にも同じリンクがあります)

# はじめに①

## ■ 本研究のメインターゲット・位置づけ

- ✓ **測定・分析のターゲット**：人間ではなく、  
**大規模言語モデル（Large Language Models, LLM）の測定**をまずは想定  
（ただし、技術的には人間も含めた統合分析も、今後はある）
  - ✓ **キー技術**：LLMやプロンプトエンジニアリングではなく、  
**IRTの分析手法の拡張（統計科学）**  
（連続的な項目反応確率データ行列の分析と、  
従来のアプローチで入手される、正答/誤答などの離散的な項目反応データ行列の分析の、  
IRTでの統合）
- ➡ **生成AIで何かをする、という研究ではなく、  
適切な利用に向けて、むしろ生成AIをより適切に測るための基礎研究**

■ **pythonコード等の格納先**: <https://github.com/mas-takayama/IRT-Measurement-for-LLMs/tree/main/JART%2024th>  
（抄録にも同じリンクがあります）

## はじめに②

### ■ 本研究の成果(本日も話している内容)

### 概ね抄録で説明している内容

- ✓ LLMの能力測定を念頭に、連続的な項目反応確率データ行列と、離散的な正誤反応データ行列を統合的に分析するIRTアルゴリズムを提案し、数値シミュレーションで妥当性を検証
  - ✓ 繰り返し測定がある場合、特に連続的な確率反応データ行列を基にした分析では、100サンプル程度でも、高い真値再現性が確認。
  - ✓ 統合分析により、離散的な反応データ行列だけの分析よりも、精度は改善し、近似的標準誤差も小さくなる
- ✓ LLMのMMLU測定の実データでの実証も行い、以下の傾向が把握できた。
    - Mistral系が、識別力の高い項目で正答しやすく、IRTでの能力推定値が上振れる傾向
    - 数学系の分野で、困難度が極端に高く、識別力が低い傾向
    - 言語・社会科学系の分野などでは1次元性が強く、数学・物理系の分野などで1次元性が弱い傾向

### 抄録未掲載の分析内容

■ pythonコード等の格納先: <https://github.com/mas-takayama/IRT-Measurement-for-LLMs/tree/main/JART%2024th>  
(抄録にも同じリンクがあります)

# 背景：LLMの質問応答能力評価

## ■ LLMの性能評価の指標

- 精度
- コストパフォーマンス
- 速度

Etc.

LLM Leaderboard 2026  
Compare 300+ AI models by the LLM Stats Score — intelligence, speed and price, updated continuously from public benchmarks and live API metrics.

Open Long Context Small (<32B) Multimodal Cheap (<\$1) Fast OpenAI Anthropic Google Meta OpenAI Mistral DeepSeek xAI

Organization Parameters Hardware Context License Modality Price Country Speed Columns Copy link Select 2-4 models to compare

| Model                 | LLM Stats | Country | License | Context | Input \$/M | Output \$/M | Speed   | Code Arena | Reasoning | Math | Coding | Search |
|-----------------------|-----------|---------|---------|---------|------------|-------------|---------|------------|-----------|------|--------|--------|
| GPT-6 Astra           | 60.3      | US      | Closed  | 1.1M    | \$10.00    | \$50.00     | 19 o/s  | —          | 58.2      | 35.9 | 48.5   | 32.6   |
| Claude Fable 5.1      | 56.3      | US      | Closed  | 1M      | \$10.00    | \$50.00     | 8 o/s   | —          | 53.3      | 43.5 | 35.0   | —      |
| GPT-5.6 Sol           | 55.1      | US      | Closed  | 1.1M    | \$5.00     | \$30.00     | 2 o/s   | 2,134      | 54.3      | 35.2 | 46.0   | 29.2   |
| Muse Spark 1.3        | 55.1      | US      | Closed  | 1.0M    | \$0.10     | \$0.20      | 8 o/s   | —          | 52.6      | —    | 41.9   | 18.3   |
| Claude Opus 5         | 55.1      | US      | Closed  | 1M      | \$5.00     | \$25.00     | 62 o/s  | 2,668      | 54.0      | 42.5 | 42.0   | 30.2   |
| Claude Mythos Preview | 55.0      | US      | Closed  | —       | —          | —           | —       | —          | 55.8      | 46.9 | 45.0   | 26.7   |
| Claude Fable 5        | 54.5      | US      | Closed  | 1M      | \$10.00    | \$50.00     | 96 o/s  | 2,003      | 51.9      | 41.3 | 45.8   | —      |
| GLM-5.3               | 53.4      | CN      | Open    | 1.0M    | \$1.20     | \$4.00      | 584 o/s | —          | 52.8      | 41.0 | 43.1   | —      |
| Kimi K3               | 53.3      | CN      | Open    | 1.0M    | \$2.85     | \$14.25     | 0 o/s   | 1,816      | 52.1      | 40.8 | 43.5   | 34.4   |
| DeepSeek-V4-Pro-0813  | 52.4      | CN      | Open    | 1.0M    | \$0.43     | \$0.87      | 29 o/s  | —          | 50.1      | 40.6 | 41.4   | —      |

<https://llm-stats.com/leaderboards/llm-leaderboard>


## ■ 特に精度面では、質問応答に関するベンチマークテストも様々な存在

- MMLU, BBH, IFEval etc.
- ただし多くの場合、多肢選択式が多く、また正答率ベースでの評価

➡ **項目ごとの難易度等も含めた評価は、近年行われつつあるが、必ずしも主流ではない**

# LLMのベンチマークテストでのIRT評価等に関する課題

- LLMの評価に項目反応理論 (IRT)を導入する研究自体は、近年見られはじめている



F. M. Polo et al. "tinyBenchmarks: evaluating LLMs with fewer examples" ICML(2024).

- 一方、LLMの基盤モデルで、公開され、利用可能なものの数は、せいぜい $10^2$ 程度のオーダー (個別にinstruct、fine-tuneしたり、量子化したりしたものは様々存在するが、その祖先となる存在は、限られている)

※ Artificial AnalysisやOpenrouterで紹介・提供されているものは、系列も含めると、400+

➡ サンプル数を十分に稼ぎながら、高い精度で評価しようと思うと、時間/金銭的成本もかかる



特定のタスクに適したLLMを選ぶにあたり、

- ・様々な角度・項目で
- ・項目の難易度等にも配慮しながら
- ・精度よく評価するには

LLMのサンプルサイズが小さくても、効率よく評価するための枠組が必要

# LLMのベンチマークテストでのIRT評価等に関する課題

## ■ LLMにおける繰り返し測定の可能性

… パラメータが凍結されているLLMに対し、chatをリフレッシュしながらであれば、繰り返し、独立な測定が可能

- ➡ 複数回同じ項目での測定が現実的でない、人間を対象とした実験とは異なり、サンプルサイズだけでなく、繰り返し測定で、測定精度の向上が見込める

## ■ LLMの出力原理:「次単語予測」

…プロンプト $Q$ やそこまでに出力されたトークン列 $\{w_1, \dots, w_{i-1}\}$ の後に、次のトークン $w_i$ が $a$ となる条件付き確率 $P(w_i = a | Q, \{w_1, \dots, w_{i-1}\})$ に基づいて、選択・出力される

- ➡ 与えた問題文プロンプトで特定の選択肢トークンが生成されるかどうか※を確認することで、質問応答の性能を見られる

※多くのLLMでは、APIで**log-probability**として、トークンの生成確率を出力可能。

連続的な正答確率の反応データ行列を、  
Nominal Response Modelで評価することで、  
少数のLLMでも、高い精度でitem calibrationが可能に


(Xiao Fei, et al. arXiv, 2026)

<https://arxiv.org/pdf/2608.02966>

## ■ 実際のLLMの測定上の課題

- ・プロンプトやLLMの訓練のされ方次第では、先頭に選択肢トークンが来ない  
(極力、最初にChain-of-Thoughtを入れて最後に結論付けるよう、訓練されているなど)
  - ・LLMによっては、log-probabilityのAPI出力が実装されていないものもある (一部のGPT、Claude系 等)
- ➡ 結局、2値/離散の項目反応データ行列しか取得できないLLMもあり、連続的な正答確率反応データ行列との統合的な分析手法の存在が望ましい

fittingのイメージ



# 本研究の目的

- LLMの出力の性質も踏まえ、多肢選択式のベンチマークについて、各項目をプロンプトとした際、
  - ・（APIで出力可能な場合）出力の冒頭のトークンで得られる選択肢の回答確率データ行列（連続）
  - ・（APIで出力できない場合などは）回答出力に基づく正誤ベースの反応データ行列（離散）を、繰り返し測定した場合も含めて、統合的に取り扱い、分析可能なIRTアルゴリズムを構築
- ➡ 従来の離散的なデータ行列のみの評価よりも、少ないサンプル数で高い精度で評価できるようにする（以下、2PL logitを仮定し、1次元IRTで議論を進めるが、多次元になっても拡張可能）
- 数値シミュレーションで検証を行うとともに、実際のLLMのベンチマークテストでの反応データも基に、上記アルゴリズムを適用し、新たな知見を獲得

## 分析対象にできるようにするデータのイメージ

(a)トークン生成確率が一部でも取得可能だった

LLMの確率測定データ（連続的な項目反応確率データ行列）

|      | Q1   | Q2   | Q3   |
|------|------|------|------|
| LLM1 | 0.2  | 0.70 | 0.9  |
| LLM2 | 0.55 | —    | 0.98 |
| LLM3 | —    | 0.64 | —    |

+

(b)必要に応じて、LLMの出力を直接評価し、正解回数をカウントしたデータ

（複数回測定による2項分布的・離散的な反応データ行列）

|      | Q1      | Q2      | Q3      |
|------|---------|---------|---------|
| LLM1 | 5回中1回正解 | 5回中4回正解 | 5回中5回正解 |
| LLM2 | 5回中3回正解 | 5回中4回正解 | 5回中5回正解 |
| LLM3 | 5回中1回正解 | 5回中3回正解 | 5回中4回正解 |

+

APIでトークン生成確率の取り出しが可能で、正答確率がある程度評価可能なLLM

（項目・LLM次第で、全選択肢のトークン生成確率の和が1に近づかない場合には、(b)のデータで推定。）

(c)仕様上、トークン生成確率が一切測定ができないなどの事情で、

LLMの出力を直接評価し、正解回数をカウントしたデータ

（複数回測定による2項分布的・離散的な反応データ行列）

|      | Q1      | Q2      | Q3      |
|------|---------|---------|---------|
| LLM4 | 5回中1回正解 | 5回中5回正解 | 5回中4回正解 |
| LLM5 | 5回中2回正解 | 5回中5回正解 | 5回中5回正解 |
| LLM6 | 5回中0回正解 | 5回中4回正解 | 5回中3回正解 |

APIでトークン生成確率の取り出しができない、もしくはLLMの事前学習・インストラクションで、先頭でいきなり選択肢トークンが出力されないLLM

- ✓ この枠組が完成すると、LLMの測定データと人間の測定データを、同一尺度で高精度で統合的に分析し、比較することも、技術的には可能になる

（医療に関する専門的判断の精度が人間と比べてどの程度か、といった、実運用にあたっての判断の材料にもなりうる）

# 提案アルゴリズムの概要① - データ行列の種類に応じたIRT

## ■ 正誤（回数）に基づく離散的な反応データ行列での最適化

$$\mu_{i,k}(\theta_i, a_k, b_k) = \frac{1}{1 + \exp(-D a_k (\theta_i - b_k))}$$
$$p(x_{i,k} | \mu_{i,k}(\theta_i, a_k, b_k)) = \mu_{i,k}^{x_{i,k}} (1 - \mu_{i,k})^{1-x_{i,k}}$$

データ全体の生成確率  $\prod_{i,k} p(x_{i,k} | \mu_{i,k}(\theta_i, a_k, b_k))$  の、負の対数尤度  $\mathcal{L}_B$  を最小化。

特に、LLMのように複数回の測定が可能の場合、全測定回数  $R$  に対し、正答回数  $r_{i,k}$  のとき、

$$\mathcal{L}_B = - \sum_{i,k} \left\{ r_{i,k} \ln(\mu_{i,k}(\theta_i, a_k, b_k)) + (R - r_{i,k}) \ln(1 - \mu_{i,k}(\theta_i, a_k, b_k)) \right\}$$

## ■ 正答確率（分布）に基づく連続的な反応データ行列での最適化

仮定: log-probability で出力された値に基づき、復元された正答選択確率  $q_{i,k}$  が、正規分布に従う。

つまり、ある個体・項目で、正答選択確率  $q_{i,k}$  が生成される生成確率は、

$$p(q_{i,k} | \mu_{i,k}(\theta_i, a_k, b_k), \sigma_{i,k}) = \text{Normal}(q_{i,k} | \mu_{i,k}(\theta_i, a_k, b_k), \sigma_{i,k}) = \frac{1}{\sqrt{2\pi\sigma_{i,k}^2}} \exp\left(-\frac{(q_{i,k} - \mu_{i,k}(\theta_i, a_k, b_k))^2}{2\sigma_{i,k}^2}\right)$$

このとき、正答確率データ行列全体の生成確率は、 $\prod_{i,k} p(x_{i,k} | \mu_{i,k}(\theta_i, a_k, b_k))$  の負の対数尤度  $\mathcal{L}_P$  を最小化

$$\mathcal{L}_P = \sum_{i,k} \left\{ \underbrace{\frac{1}{2\sigma_{i,k}^2} (q_{i,k} - \mu_{i,k}(\theta_i, a_k, b_k))^2}_{\text{分散の逆数を重みとする最小二乗法と一緒}} + \underbrace{\frac{1}{2} \ln(2\pi\sigma_{i,k}^2)}_{\text{最小化に当たっては、定数なので無視してゼロとしてよい}} \right\}$$

**$\sigma_{i,k}$  さえわかれば、分散の逆数を重みとする最小二乗法と一緒**

➡ 前提として、APIを通じた測定で、なぜか揺らぎが観測されるlog-probabilityの揺らぎがガウシアンに従っているか否かは、実はわからないものの、数式上はこのほうが扱いやすいことから、あくまで最適化プロセスにおけるworking likelihoodとして、正規分布を採用。

# 提案アルゴリズムの概要② -統合された推定アルゴリズム

✓ 離散的な正誤応答と、log-probability由来の正答確率は、  
同じLLMで両方得られる場合でも、異なる観測チャネルとして、別々に測定可能。

そのため、全体のデータ生成確率の最適化という意味では、両方のjoint likelihoodとして、各目的関数を単純に足せばよい。つまり、

$$\begin{aligned}\mathcal{L} &= \mathcal{L}_B + \mathcal{L}_P \\ &= - \sum_{\text{discrete data}, i, k} \left\{ r_{i,k} \ln \left( \mu_{i,k}(\theta_i, a_k, b_k) \right) + (R - r_{i,k}) \ln \left( 1 - \mu_{i,k}(\theta_i, a_k, b_k) \right) \right\} \\ &\quad + \sum_{\text{probability data}, i, k} \frac{1}{2\sigma_{i,k}^2} (q_{i,k} - \mu_{i,k}(\theta_i, a_k, b_k))^2\end{aligned}$$

を最小化する問題にする。

## Step 1: $\theta_i$ の更新

$a_k, b_k$ を固定した上で、

$$\theta_i^{\text{new}} = \arg \min_{\theta_i \in R} (\mathcal{L}_B + \mathcal{L}_P)$$

## Step 2: $a_k, b_k$ の更新

$\theta_i$ を固定した上で、

$$(a_k^{\text{new}}, b_k^{\text{new}}) = \arg \min_{a_k > 0, b_k \in R} (\mathcal{L}_B + \mathcal{L}_P)$$

※ その後、適宜 $\{\theta_i^{\text{new}}\}$ で標準化を実施し、 $a_k^{\text{new}}, b_k^{\text{new}}$ もそのスケールを合わせる。

ループ終了条件A:  $\max(|a_k^{\text{new}} - a_k^{\text{old}}|) < \epsilon_a$

ループ終了条件B:  $\max(|b_k^{\text{new}} - b_k^{\text{old}}|) < \epsilon_b$

ループ終了条件C:  $\max(|\theta_i^{\text{new}} - \theta_i^{\text{old}}|) < \epsilon_\theta$

ループ終了要件を全て満たすかチェックしながら、この部分を繰り返す

(ただし、発散を防止するため、実際の各パラメータの探索では、閾値を設ける)

# 提案アルゴリズムの概要③ - 近似的標準誤差の評価

負の対数尤度 $\mathcal{L}(\psi)$  ( $\psi$ は項目パラメータもしくは能力パラメータのいずれか) について、**Fisher情報量**自体は、正則条件を満たしていれば、

$$I(\psi) = E \left[ \frac{\partial^2 \mathcal{L}(\psi)}{\partial \psi \partial \psi^\dagger} \right]$$

項目パラメータの最尤推定値 $\hat{\psi}$ の分布は、漸近的に分散 $I^{-1}(\psi)$ のガウス分布となるため、標準誤差 $SE(\hat{\psi}_i)$ は、

$$SE(\hat{\psi}_i) = \sqrt{[I^{-1}(\psi)]_{ii}}$$

※ ただし、今回の計算では、簡略化のため、 $a_k, b_k$ の標準誤差計算では $\theta_i$ を固定し、逆もまた然りで、**同時不確定性までは考慮していない、近似的標準誤差**であることに留意。

実際の計算に当たっては、 $\eta_{ik} = Da_k(\theta_i - b_k)$ および $\mu_{ik} = \frac{1}{1 + \exp(-\eta_{ik})}$ とにおいて、

log-probabilityベースの連続的な項目反応データ行列の場合

$$I_{probability\ data}(\psi) = \frac{\{\mu_{ik}(1 - \mu_{ik})\}^2}{\sigma_{i,k}^2} \left( \frac{\partial \eta_{ik}}{\partial \psi} \right) \left( \frac{\partial \eta_{ik}}{\partial \psi} \right)^\dagger$$

正答/誤答ベースの離散的な項目反応データ行列の場合

$$I_{discrete\ data}(\psi) = R\mu_{ik}(1 - \mu_{ik}) \left( \frac{\partial \eta_{ik}}{\partial \psi} \right) \left( \frac{\partial \eta_{ik}}{\partial \psi} \right)^\dagger$$

# 【補足】正解確率データ行列側の正答選択確率・分散の取り扱い

## ■ 正答選択確率

$R$ 回測定の平均値を $q_{i,k}$ として採用

## ■ 分散

- ✓ 項目/個体ごとの分散 $\sigma_{i,k}^2$ も、事前にはわからない。  
代わりに、独立反復近似のもと、 $R$ 回の確率測定を通じて得られた  
標本分散 $s_{i,k}^2$ を使って、

$$\sigma_{i,k}^2 \approx \frac{s_{i,k}^2}{R}$$

と表すことを基本とする。

- ✓ 確率が1や0に近づくほど、 $s_{i,k}$ も極端に小さく、重みが過大になる（厳密な0/1だと発散する）ため、

$$\sigma_{i,k}^2 = \frac{s_{i,k}^2}{R} + \tau^2$$

というように、正の数として $\tau^2$ を加え、発散を防止。

- ✓  $\tau^2$ の取り方は、 $s_{i,k}=0$ でも、測定回数に応じた重みが、離散データの測定と同程度となるようにする。  
具体的には、測定回数 $R$ のとき、離散データでの情報量は $RD^2a^2\mu(1-\mu)$ となり、  
最大値は $\mu = 0.5$ のときの $0.25RD^2a^2$ であることにも鑑み、暫定的に、

$$\tau^2 = \frac{1}{4R}$$

としている。

# 提案アルゴリズムに基づく数値シミュレーション

## ■ 共通条件：離散/連続ともに5回ずつ測定した状況を仮想的に生成

- 項目数は100で固定。
- 項目パラメータ（識別力、困難度）と能力値 $\theta$ の正解データは、全て乱数で生成。  
(項目パラメータは一様分布、能力値は標準正規分布を仮定)
- 正答回数の離散反応データ行列は、2PL logitで定まる確率に基づき乱数で、5回の独立試行で生成。
- 連続的な正答確率反応データ行列は、2PL logitにノイズを入れて、正規分布的に5回の独立試行で生成し、確率の平均値と標本分散の値を活用。

## ■ 実験①：各パラメータの真値の再現性の検証

IRT分析により推定した値を比較し、RMSE(Root Mean Squared Error)により、真値の再現性を検証

条件①-A 離散データ行列のみ( $n=100$ )

条件①-B 確率データ行列のみ( $n=100$ )

条件①-C 離散データ行列( $n=100$ )と、確率データ行列( $n=100$ )を一体的に分析

## ■ 実験②：サンプルサイズの変化による項目パラメータの標準誤差の変化

近似的標準誤差のサンプルサイズ依存性を確認（理論上は、サンプルサイズの平方根に反比例）

条件②-A 離散データ行列のみ

条件②-B 確率データ行列のみ

条件②-C 離散データ行列(このサンプルサイズを様々変動させる)と、確率データ行列( $n=50$ )を一体的に分析

条件②-D 離散データ行列( $n=50$ )と、確率データ行列(このサンプルサイズを様々変動させる)を一体的に分析

# 数値シミュレーション結果① -各パラメータの真値再現性

※ 誤差棒は全て、近似的標準誤差。直線に乗っている（RMSEが小さい）ほど、推定値が真値に近い




識別力a  
(項目数100)

困難度b  
(項目数100)




離散データのみで測定され  
た群theta(n=100)

連続的な反応確率デー  
タのみで測定された群の  
theta (n=100)





離散データのみでの5回測  
定/分析した場合  
(n=100)



連続的な反応確率デー  
タのみでの5回測定/分析  
した場合(n=100)



離散のみでの5回測定  
(n=100)と、  
連続的な反応確率デー  
タのみでの5回測定  
(n=100)を一体的に  
分析した場合




- ✓ 連続的な確率データ行列のみの場合の方が、離散的な場合よりもRMSEが小さい（真値再現性が高い）  
➡ 連続値にフィットする方が情報量が多く、効果的な推定が可能 **（期待通りの挙動）**
- ✓ 離散データの場合よりも、統合して分析する方が、RMSEが小さい（真値再現性が高い）  
➡ 異なる観測形式として分断されていたデータを一緒に使うことで、精度が向上する **（統合によるご利益）**


# 数値シミュレーション結果② -サンプルサイズと項目パラメータの近似的標準誤差

※ 誤差棒は全て、10回の別々の乱数生成で試行して得られたRMSSEの標準誤差。


離散データ行列のみで分析




確率データ行列のみで分析



離散データ行列(このサンプルサイズを様々変動させる)  
+ 確率データ行列(n=50)を一体的に分析



離散データ行列(n=50)+ 確率データ行列(このサンプルサイズを  
様々変動させる)を一体的に分析



- ✓ 項目パラメータa, bの推定値の近似的標準誤差は、**サンプルサイズの逆数の平方根で概ねfitされる→期待通りの挙動**
- ✓ 統合しても、それぞれのサンプルサイズを動かした場合の標準誤差の挙動は、ほぼ右側への平行移動。  
つまり、**統合により、異なる観測形式として分断されていたデータを一緒に使うことで、標準誤差がさらに小さくなる→統合によるご利益**

以上の実験から、本研究で提案する新たなアルゴリズムは、期待通りの挙動を示している点で妥当なものであり、また統合的分析での精度向上等にも貢献していることが確かめられた

# 実際のLLMのベンチマーク測定データでの検証

## ■ MMLU (Massive Multitask Language Understanding)

- 57分野 (abstract algebra, astronomy, US foreign policyなど多岐にわたる)
- 計14,042問
- LLMの定番ベンチマークの一つ

D. Hendrycks et al., ICLR2021,  
<https://openreview.net/forum?id=d7KBjmI3GmQ>

## ■ 各LLMのMMLU評価結果の公開先 (問題レベルで！)

### Open LLM Leaderboard by Hugging Face

- オープンLLMの性能検証
- MMLUについては  
6000以上のデータ  
(全て5 shotsで測定)
- **正答確率データ**も公開



### HELM Leaderboards by Stanford CRFM

- OpenAI, gemini,  
claudeなども性能検証
- MMLUについては  
80程度のデータ  
(全て5 shotsで測定)
- **正答/誤答**の生回答のみ



Center for  
Research on  
Foundation  
Models

両方で測定されている22件のLLM※も含め、  
本研究で開発した方法で、統合的にIRT分析することが可能

(ただし、いずれも1回ずつの測定なので、負の対数尤度の算出については適宜見直しをしている)

※ Deepseek, Gemma, Llama系の一部のモデル等  
これらについては、確率データ/正誤データの両方を測定に活用

# MMLUの応答に関する分析結果① - 全体的な測定精度

## ■ MMLUの項目パラメータに関する精度評価

(推定値や標準誤差は、全て分野ごとにLLMの能力推定値に対して施した標準化に沿ったスケール)

| 識別力推定値のRoot Mean Squared Standard Error | 困難度推定値のRoot Mean Squared Standard Error |
|-----------------------------------------|-----------------------------------------|
| 0.043                                   | 0.368                                   |

- ✓ 困難度パラメーターのRMSSEは、MMLUの中には困難度が高すぎる問題も多く、推定が安定的に定まらないため、上振れているが、識別力の推定は、Open LLM Leaderboardでサンプルサイズが確保できていることもあり、安定する傾向


## ■ LLMの能力測定に関する精度評価

| LLMのタイプ                                     | LLMの能力推定に関するRoot Mean Squared Standard Error<br>(標準化は分野ごとに能力推定値に対して実施) |
|---------------------------------------------|------------------------------------------------------------------------|
| ①Open LLM LeaderboardのみにデータがあるLLM (6487モデル) | 0.233                                                                  |
| ②HELM LeaderboardsのみにデータがあるLLM(57モデル)       | 0.561                                                                  |
| ③両方にデータがあるLLM(22モデル)                        | 0.194                                                                  |

- ✓ 特に③については、HELMデータなしでOpen LLM Leaderboardのデータのみで推定した場合には0.237となり、0.194までの減少 (**約18.4%減**) は、統合分析で、HELMデータも活用して推定精度が向上したことを示唆


# MMLUの応答に関する分析結果② -モデル別の傾向の抽出

## ■ 例. high school psychology



✓ 概ね正答率と $\theta$ 推定値の間に正の相関がみられるが、高正答率側で複数系統への枝分かれ

### 拡大・モデル系統別色分け



✓ **Mistral系**において、識別力の高い項目で特に正答率が高くなり、upper branchを構成している可能性

➡同規模モデルに比べて、単純な知識保持より reasoning・STEM・code capabilityに強みがあるモデルなので、識別力の高い問題がこれらの領域であれば、Mistral系の強みが現れたと考えられる

# MMLUの応答に関する分析結果③- 分野別の測定能力

## ■ 識別力の高い分野の例

| 分野                                  | 項目数 | 識別力の推定値の平均 | 困難度の推定値の平均 | 困難度推定値が負となっている項目の割合（≡ 平均的なLLMにとって比較的易しめの問題） |
|-------------------------------------|-----|------------|------------|---------------------------------------------|
| High School Government and Politics | 193 | 1.999      | -0.408     | 87.6%                                       |
| Miscellaneous                       | 783 | 1.697      | 0.022      | 79.2%                                       |
| High School Psychology              | 545 | 1.653      | -0.102     | 81.3%                                       |

## ■ 識別力の低い分野の例


| 分野                      | 項目数 | 識別力の推定値の平均 | 困難度の推定値の平均 | 困難度推定値が負となっている項目の割合（≡ 平均的なLLMにとって比較的易しめの問題） |
|-------------------------|-----|------------|------------|---------------------------------------------|
| High School Mathematics | 270 | 0.229      | 3.576      | 6.7%                                        |
| Abstract Algebra        | 100 | 0.250      | 3.472      | 8.0%                                        |
| College Mathematics     | 100 | 0.256      | 3.542      | 8.0%                                        |

✓ 数学系において、問題が全体的にLLMにとって極端に難しい傾向にあり、識別力が低い要因の一つである可能性  
(ただし、そもそも次元性が成立しているかどうかも含めて、検証が必要)


# MMLUの応答に関する分析結果④- 分野別の1次元性の検証

## ■ 1次元性が強い群

例1. high school government and politics




例2. marketing




## ■ 1次元性が弱い群

例3. abstract algebra



例4. high school mathematics



✓ 大雑把な傾向として、  
歴史・政治など、言語的・概念的知識を問う分野では一次元性が強く、  
数学・物理など、異なる能力を問う要素が複数含まれる分野では一次元性が弱い（多次元モデルの方が適切）

# 本発表のまとめ

## ■ 本研究の成果（冒頭の再掲）

- ✓ LLMの能力測定を念頭に、連続的な項目反応確率データ行列と、離散的な正誤反応データ行列を統合的に分析するIRTアルゴリズムを提案し、数値シミュレーションで妥当性を検証
- ✓ 繰り返し測定がある場合、特に連続的な確率反応データ行列を基にした分析では、100サンプル程度でも、高い真値再現性が確認。
- ✓ 統合分析により、離散的な反応データ行列だけの分析よりも、精度は改善し、近似的標準誤差も小さくなる
- ✓ LLMのMMLU測定の実データでの実証も行い、以下の傾向が把握できた。
  - Mistral系が、識別力の高い項目で正答しやすく、IRTでの能力推定値が上振れる傾向
  - 数学系の分野で、困難度が極端に高く、識別力が低い傾向
  - 言語・社会科学系の分野などでは1次元性が強く、数学・物理系の分野などで1次元性が弱い傾向

## ■ 本研究成果の貢献・社会的意義

- ✓ LLMそのものの測定の効率化に貢献（校正済データセットからの抽出による測定コスト削減や、ベンチマークの長寿命化）
- ✓ 人間と同一尺度での比較による、LLMの領域専門性の検証を可能にする  
（例. 医療に関する専門的判断の精度が人間と比べてどの程度か、等）
- ✓ 人間を対象とする測定項目の、LLMをテストベッドとした事前校正の高度化・高精度化を可能にしよう

## ■ 今後の課題・展望

- ✓ 標準誤差の計算における妥当性の深掘り（ $\tau^2$ の適切な扱いと、統合にあたっての重みづけの考え方）
- ✓ LLMのベンチマーク測定のIRT分析結果に関する解釈の深掘り（高識別力傾向の分析）や、数学・物理等の領域での傾向を踏まえた、多次元IRTの検討

**以下、参考資料**

# 近似的標準誤差の評価式の詳細

厳密には、Fisher情報量行列を各パラメータについて計算した上で、その逆行列の対角成分の逆数の平方根をとることで計算されるが、結論だけ提示すると、

$$SE(\hat{\theta}_i) = \left[ \sum_k D^2 \hat{a}_k^2 \left\{ R_{ik}^{\text{bin}} \hat{\mu}_{ik}(1 - \hat{\mu}_{ik}) + \delta_{ik}^{\text{lp}} \frac{\{\hat{\mu}_{ik}(1 - \hat{\mu}_{ik})\}^2}{\sigma_{ik}^2} \right\} \right]^{-1/2}$$

$$SE(\hat{a}_k) = \sqrt{\frac{\sum_i D^2 \left[ \delta_{ik}^{\text{bin}} R_{ik}^{\text{bin}} \hat{\mu}_{ik}(1 - \hat{\mu}_{ik}) + \delta_{ik}^{\text{lp}} \frac{\{\hat{\mu}_{ik}(1 - \hat{\mu}_{ik})\}^2}{\sigma_{ik}^2} \right] \hat{a}_k^2}{A_k B_k - C_k^2}}$$

$$SE(\hat{b}_k) = \sqrt{\frac{\sum_i D^2 \left[ \delta_{ik}^{\text{bin}} R_{ik}^{\text{bin}} \hat{\mu}_{ik}(1 - \hat{\mu}_{ik}) + \delta_{ik}^{\text{lp}} \frac{\{\hat{\mu}_{ik}(1 - \hat{\mu}_{ik})\}^2}{\sigma_{ik}^2} \right] (\hat{\theta}_i - \hat{b}_k)^2}{A_k B_k - C_k^2}}$$


$$A_k = \sum_i D^2 \left[ \delta_{ik}^{\text{bin}} R_{ik}^{\text{bin}} \hat{\mu}_{ik}(1 - \hat{\mu}_{ik}) + \delta_{ik}^{\text{lp}} \frac{\{\hat{\mu}_{ik}(1 - \hat{\mu}_{ik})\}^2}{\sigma_{ik}^2} \right] (\hat{\theta}_i - \hat{b}_k)^2$$

$$B_k = \sum_i D^2 \left[ \delta_{ik}^{\text{bin}} R_{ik}^{\text{bin}} \hat{\mu}_{ik}(1 - \hat{\mu}_{ik}) + \delta_{ik}^{\text{lp}} \frac{\{\hat{\mu}_{ik}(1 - \hat{\mu}_{ik})\}^2}{\sigma_{ik}^2} \right] \hat{a}_k^2$$


$$C_k = - \sum_i D^2 \left[ \delta_{ik}^{\text{bin}} R_{ik}^{\text{bin}} \hat{\mu}_{ik}(1 - \hat{\mu}_{ik}) + \delta_{ik}^{\text{lp}} \frac{\{\hat{\mu}_{ik}(1 - \hat{\mu}_{ik})\}^2}{\sigma_{ik}^2} \right] \hat{a}_k (\hat{\theta}_i - \hat{b}_k)$$

# 標準誤差について、項目パラメータ数を振ってシミュレーションした結果


離散データ行列のみで分析(n=100)




確率データ行列のみで分析(n=100)



離散データ行列(n=100)と、  
確率データ行列(n=100)を一体的に分析



離散データ行列(n=100)と、確率データ行列(n=100)、  
さらに離散 or 確率データのいずれか一方が項目ごとに測定された群  
(n=50、離散の割合は3割)も加えた分析



- ✓ 項目パラメータa, bの推定値の標準誤差は項目数を変えてもほとんど変化しない
- ✓ thetaの推定値の標準誤差は、項目数の逆数の平方根で概ねfitされる
- ✓ 統合しても、それらの**thetaの推定値の標準誤差の項目数依存性はほとんど変わらない**

# Open LLM Leaderboardにおける確率データの扱いの例外処理

✓ 今回の提案手法では、確率反応データ行列側も、複数回の測定を前提に、

$$\mathcal{L}_P = \sum_{i,k} \frac{1}{2\sigma_{i,k}^2} (q_{i,k} - \mu_{i,k}(\theta_i, a_k, b_k))^2$$

$$I_{probability\ data}(\psi) = \frac{\{\mu_{ik}(1 - \mu_{ik})\}^2}{\sigma_{i,k}^2} \left( \frac{\partial \eta_{ik}}{\partial \psi} \right) \left( \frac{\partial \eta_{ik}}{\partial \psi} \right)^\dagger$$

としている

- ✓ しかし、Open LLM Leaderboardは、正解選択肢の確率値のデータがある一方、APIを通じて測定したものではなく、各モデルのパラメータから直接計算された確率であるため、
- ・揺らぎのない確定的な値であり、
  - ・かつ $\sigma_{i,k}^2$ が測定できない

✓ よって、Leaderboardを使った分析では例外的に、

$$\mathcal{L}_P = - \sum_{i,k} (q_{i,k} \ln(\mu_{i,k}(\theta_i, a_k, b_k)) + (1 - q_{i,k}) \ln(1 - \mu_{i,k}(\theta_i, a_k, b_k)))$$
$$I_{probability\ data}(\psi) = \mu_{ik}(1 - \mu_{ik}) \left( \frac{\partial \eta_{ik}}{\partial \psi} \right) \left( \frac{\partial \eta_{ik}}{\partial \psi} \right)^\dagger$$

と処理している。

それでも、確率データ行列と2PLで推定される確率行列のcross entropyの最小化となっており、負の対数尤度の数式的構造からみても、 $\mathcal{L}_B$ と同じ重みで統合して最小化することは自然と考えられるが、標準誤差の現れ方等には影響する可能性がある。

(ただし、データ生成確率という意味での解釈は困難になる)

## $\tau^2$ に関する取り扱いの補足

✓  $\tau^2$ が具体的に効いてくるところは、

$$\mathcal{L}_P = \sum_{i,k} \frac{1}{2\left(\frac{s_{i,k}^2}{R} + \tau^2\right)} (q_{i,k} - \mu_{i,k}(\theta_i, a_k, b_k))^2$$

$$I_{probability\ data}(\psi) = \frac{\{\mu_{ik}(1 - \mu_{ik})\}^2}{\frac{s_{i,k}^2}{R} + \tau^2} \left(\frac{\partial \eta_{ik}}{\partial \psi}\right) \left(\frac{\partial \eta_{ik}}{\partial \psi}\right)^\dagger$$

であり、

- パラメータの推定精度については、最小化にあたっての $\mathcal{L}_P$ と $\mathcal{L}_B$ のバランスに影響し、結果的に収束値が変動する可能性がある
- 近似的標準誤差については、 $\tau^2$ が大きいほど、確率反応データ行列側で大きく出力されるということが考えられる。




- 厳密には、 $\tau^2$ による推定値のずれ、近似的標準誤差に関する感度分析が必要
- ただし、現実的には妥当な $\tau^2$ を決定することも難しく、場合によっては前のページのLeaderboardのような負の対数尤度・Fisher情報量を線形で重ね合わせていくというアプローチも、今後考えられる

## 本研究の応用可能性1: LLMそのものの測定

1つのLLMにベンチマークテストを解かせるにあたり、知りたい能力精度に応じて、  
解かせる問題数を減らせる

⇒ 効率的かつ、問題情報が晒される回数・リスクも減るので、  
問題の「寿命」を縮めにくくなる

- ✓ IRTでLLMの能力を測定することで、問題数を減らしても、ベンチマークテストを全部受けさせるのと同等程度以上の精度に近づけられることも、別の研究で示されている。




F. M. Polo et al. "tinyBenchmarks: evaluating LLMs with fewer examples"  
ICML(2024).

- ✓ 問題を何度も晒せば晒すほど、「問題+正答」でのデータが出回り、それ自体を後発のLLMが学習してしまうことで、ベンチマークとして機能しなくなる可能性（人間でいう、問題漏洩に似ている）
- ✓ ベンチマークテストのライフサイクルが長ければ長いほど、ベンチマークテストのリメイクの頻度を減らせるので、少ない問題数での効率的な測定ができるなら、LLMによって解かせる問題を変えるなどの対応がベスト

## 本研究の応用可能性2: 人間とLLMの同一の「能力」軸上での比較

人間の基準の相場観が分かれば、LLMのドメイン専門家としての熟達度がわかり、  
応用上どの程度LLMの出力を信用/チェックするかの議論も可能に



技術的には、

- ・LLMで測定された項目パラメータを用いて、人間のドメイン専門家の測定で提供する
  - ・人間のドメイン専門家で項目パラメータを測定し、LLMの測定でも適用する
- のいずれか一方で対応可能

ただ、人間のドメイン専門家の水準が分らないと、  
左記のグラフのような判断基準の策定も不可能

➡ ここまですると思ったら、いずれにせよ  
人間のドメイン専門家を対象とした実験が必要

### 【人間のドメイン専門家に対して測定する際の課題】

- ・問数が多い場合、人間に対する調査不可も大きい  
➡ 右図のように、一部の問題を抽出して、  
人によって違う問題を解いてもらい、IRT分析するデザインも有効？
- ・回答条件の精査（調べて回答とかをありにするか否かなど。）
- ・対象者の要件定義（ドメイン専門家の範囲）
- ・人を対象とする調査なので、倫理的配慮も検討が必要
- ・そもそも、同じ能力軸で測ってよいのかは未知数  
（人間でいう「能力」とLLMでの「能力」がどれだけ一致しているか？）



Aが解く問題セット

|     |     |     |     |     |
|-----|-----|-----|-----|-----|
| 問題1 | 問題2 | 問題3 | 問題4 | 問題5 |
|-----|-----|-----|-----|-----|

政策ドメイン専門家A



Bが解く問題セット

|     |     |     |     |     |
|-----|-----|-----|-----|-----|
| 問題3 | 問題4 | 問題5 | 問題6 | 問題7 |
|-----|-----|-----|-----|-----|

政策ドメイン専門家B



Cが解く問題セット

|     |     |     |     |     |
|-----|-----|-----|-----|-----|
| 問題5 | 問題6 | 問題7 | 問題8 | 問題1 |
|-----|-----|-----|-----|-----|

政策ドメイン専門家C

## 本研究の応用可能性3: 人間に対する調査のテストベッドのLLMの活用

LLMを用いた、試験問題/アンケート調査の反応の事前検証や、改善の検討も可能に  
⇒ 教育学/心理学/認知機能科学の発展にも貢献できる可能性

【人間を対象とする実験に先立つ事前検証・項目改善のサイクルのイメージ】



- ✓ 人間相手には、試せる回数・機会が限られ、一度に多くのサンプルでの検証を要する一方、クロードな環境のLLMでの事前検証は、回数やサンプル数に関するハードルが低く、調査目的に応じて、徹底的に項目を練り上げることができる